

Iván David Suarez Ruiz Código: 202512491
 Diego Leonardo Barón Código: 202525657
 Miguel Benavides Lara Código: 202525326
 Santiago Palacios Loaiza Código: 202523012

Proyecto Final

1. Definición Problemática y Entendimiento Negocio

La empresa analizada es IMG Procesos y Tecnología, ubicada en Bogotá, Colombia, con más de 15 años de experiencia en el desarrollo de soluciones orientadas a la centralización, gestión y disponibilidad de la información para sus clientes.

Actualmente, los colaboradores de IMG deben diligenciar un formato para registrar las actividades de los proyectos en los que participan. Esta práctica fragmentada impide la consolidación de la información en un repositorio centralizado, dificultando el seguimiento oportuno, la trazabilidad de las tareas, el mapeo de los costos operacionales y la medición real de la productividad. Esta situación no solo limita la visibilidad operativa, sino que incrementa el riesgo de subestimación de tiempos y costos, un fenómeno recurrente en la industria del software que afecta directamente la rentabilidad de los proyectos.

La falta de un control preciso entre los costos reales y los costos planificados dificulta la toma de decisiones presupuestales y la evaluación de la rentabilidad de los proyectos. Por otro lado, la ausencia de datos consolidados impide un análisis objetivo del desempeño de los colaboradores, ya que no se cuenta con información confiable sobre el tiempo invertido, las tareas ejecutadas o los niveles de productividad individual y colectiva.

Por último, también se limita el acceso a métricas clave de desempeño en tiempo real, como el avance porcentual de los proyectos, la eficiencia operativa o el grado de cumplimiento de los objetivos. Esta situación afecta de manera directa la capacidad de la empresa para realizar un seguimiento continuo, anticiparse a desviaciones, lo que incrementa el riesgo de subestimación de costos y plazos. En consecuencia, se compromete la rentabilidad de los proyectos, la satisfacción de los clientes y la competitividad de la organización en el mercado.

Objetivo General

Diseñar e implementar una solución integral de registro, integración y análisis de datos que permita optimizar la trazabilidad, productividad y gestión de los proyectos en IMG Procesos y Tecnología, facilitando la toma de decisiones basadas en información confiable.

Objetivos Específicos

- Centralizar la información de registro de actividades de los empleados en un repositorio único y estructurado.
- Automatizar y estandarizar el proceso de captura de datos mediante una API transaccional y una interfaz de usuario intuitiva.
- Desarrollar un dashboard analítico que integre métricas de desempeño de proyectos, costos y productividad del talento humano.
- Mejorar la visibilidad y control sobre la ejecución de proyectos mediante indicadores.
- Fortalecer la toma de decisiones estratégicas basadas en evidencia, mediante reportes e indicadores.

Definición de KPIs

KPI	Descripción	Fórmula / Método de Cálculo	Propósito
Porcentaje de	Mide la proporción de proyectos	(Proyectos con desviación >	Detectar proyectos

proyectos en riesgo	que presentan desviaciones superiores al 20% en tiempo o costo.	$20\% / \text{Total proyectos} \times 100$	críticos y anticipar acciones correctivas.
Cumplimiento horas proyectos (%)	Compara las horas reales con las horas presupuestadas en proyectos.	$(\text{Horas planificados} / \text{Horas reales}) \times 100$	Controlar sobrecostos en horas y rentabilidad de proyectos.
Cumplimiento horas tareas (%)	Compara las horas reales con las horas presupuestadas en tareas.	$(\text{Horas planificados} / \text{Horas reales}) \times 100$	Controlar sobrecostos en horas y rentabilidad de tareas.
Porcentaje de avance por proyecto	Porcentaje del progreso reportado sobre el total de tareas planificadas.	$(\text{Tareas completadas} / \text{Tareas totales}) \times 100$	Medir el avance general y la adherencia al plan.
Productividad promedio por empleado (horas/tarea)	Mide el tiempo promedio que tarda cada colaborador en completar una tarea	$\text{Total horas registradas} / \text{Total tareas completadas}$	Comparar desempeños y detectar cuellos de botella.

Tabla 1. KPIs relacionados con los productos de datos

2. Ideación

Se propone el diseño e implementación de una **solución integral basada en datos** para optimizar la trazabilidad, el control y la toma de decisiones estratégicas en la gestión de **proyectos y talento humano**. La iniciativa transformará la información operativa dispersa en conocimiento accionable mediante el desarrollo de **cuatro componentes** interconectados.

- **Integración de datos:**
 - **Finalidad:** Centralizar la información de registro de actividades de los empleados en un repositorio unificado (Data Lake/Warehouse).
 - **Impacto:** Elimina la dependencia de canales informales, garantizando la disponibilidad, consistencia y trazabilidad.
- **API de registro de actividades:**
 - **Finalidad:** Desarrollar una API transaccional con una interfaz gráfica amigable para el registro de actividades en tiempo real.
 - **Impacto:** Reemplaza los formatos manuales, permitiendo a los empleados asignar actividades a proyectos específicos y enviarlas automáticamente al repositorio.
- **Dashboard de gestión y desempeño:**
 - **Finalidad:** Crear un tablero de control interactivo para la analítica de proyectos y productividad.
 - **Impacto:** Facilita la monitorización de tendencias y soporta la toma de decisiones basada en evidencia.
- **Modelo de Analítica:**
 - **Finalidad:** Implementar un Modelo de Machine Learning para la estimación del tiempo total de los proyectos, basándose en variables clave como horas planificadas y número de tareas.
 - **Estrategia de Datos:** Inicialmente, se utilizará un dataset externo con características similares a la estructura de la empresa (dada la limitación de datos actuales).
 - **Visión Futura:** El modelo está diseñado para ser ajustado y validado a corto plazo con los datos históricos propios de la empresa, una vez que el sistema de registro esté en funcionamiento.

A continuación, se presenta los requerimientos funcionales y no funcionales para cada uno de los productos de datos:

Producto de datos	Descripción
ETL	Requerimientos Funcionales

	Centralización: Integrar en un único repositorio toda la información de los formularios. Estandarización: Unificar y estructurar los datos heterogéneos en un formato común. Calidad de datos: Aplicar validaciones automáticas para detectar registros incompletos. Integración final: Almacenar los resultados de la ETL en un data lake corporativo para consulta.
	Requerimientos No Funcionales Calidad e integridad: Los datos cargados deben ser completos, consistentes y libres de duplicados. Disponibilidad: La plataforma de integración debe mantener una disponibilidad mínima del 99.5%. Eficiencia: El tiempo total de procesamiento por lote (extracción, transformación y carga) no debe superar los 30 minutos para datasets estándar (~100k registros).

Tabla 2. Requerimientos funcionales ETL.

Producto de datos	Descripción
API	Requerimientos Funcionales Gestión de Registros de Actividad: El sistema debe permitir a los usuarios registrar actividades a través de una interfaz web, capturando tarea, proyecto, fecha, hora de inicio y fin, y una descripción de la actividad realizada. Integridad y Validación de Datos: El sistema debe asociar automáticamente cada registro al proyecto y colaborador correspondiente, validando su existencia y estado activo previo al guardado. Integración y Usabilidad: La API debe garantizar la sincronización automática e inmediata de los registros con el repositorio central de datos (Data Warehouse o Data Lake).
	Requerimientos No Funcionales Disponibilidad: El servicio debe garantizar un 99.9% de disponibilidad. Escalabilidad: La API debe poder manejar un aumento en el número de solicitudes concurrentes. Baja latencia: El tiempo máximo de respuesta para el registro o consulta de actividades no debe superar los 10 segundos en condiciones normales de carga.

Tabla 3. Requerimientos funcionales API.

Producto de datos	Descripción
Dashboard	Requerimientos Funcionales El dashboard debe visualizar indicadores clave de productividad, cumplimiento de tiempos y avance de proyectos, integrar comparativos entre horas planificadas y reales con sus desviaciones, permitir análisis en distintos niveles de granularidad, ofrecer filtros por empleado, proyecto, equipo o estado del proyecto, actualizar los datos automáticamente desde el repositorio centralizado, facilitar la exportación de reportes en formatos estándar (PDF, Excel, CSV) junto con la generación automática de informes, y contar con una interfaz interactiva e intuitiva que permita interpretar rápidamente la información mediante gráficos, tarjetas y paneles comparativos.
	Requerimientos No Funcionales El dashboard debe garantizar una disponibilidad mínima del 99.5% para permitir consultas continuas, mantener tiempos de carga y actualización de visuales inferiores a 10 segundos en condiciones normales y asegurar la escalabilidad necesaria para soportar incrementos en el número de proyectos, empleados o registros sin afectar el rendimiento. El sistema debe garantizar seguridad y privacidad mediante el cifrado o la restricción de acceso a datos sensibles según el nivel jerárquico, asegurar que todos los indicadores provengan del repositorio central para mantener la integridad y trazabilidad de la información, y desarrollarse con herramientas modernas de análisis y visualización compatibles con la infraestructura existente, como Power BI, Tableau o Looker Studio.

Tabla 4. Requerimientos funcionales Dashboard.

3. Responsable

La información recopilada en el proyecto es de carácter corporativo y operativo, sin involucrar datos personales de los trabajadores, por lo tanto, las directrices de la Ley 1581 de 2012 (Congreso de Colombia, 2012) no aplican directamente. Aún así, es necesario salvaguardar los derechos laborales y proteger la integridad de la información corporativa mediante principios de seguridad y confidencialidad.

En materia de transparencia, se identificó la necesidad de contar con un canal de comunicación abierto y continuo que permita explicar el propósito del sistema, los datos procesados y los beneficios esperados, fomentando una cultura de confianza.

Debe ser explícito que los reportes generados se utilizarán exclusivamente para métricas operativas, trazabilidad de costos e identificación de oportunidades de mejora. Desde una perspectiva ética, se requiere asegurar que el proyecto mantenga su enfoque en la productividad y no derive en mecanismos de control individual. Para ello, es fundamental una política interna de tratamiento de datos no personales que garantice decisiones justas y respetuosas (Banco Interamericano de Desarrollo, 2019).

En los productos de datos planteados se debe garantizar que esta información, de gran valor para la compañía, se mantenga al alcance de personal autorizado. (ESEID, 2024). Para la mitigación de este riesgo es necesario implementar controles de acceso a partir de roles y perfiles de usuario en la API de captura de información. Dentro de esta definición de roles y perfiles de usuario, se debe llevar a cabo un proceso de clasificación y etiquetado de información para su disponibilidad oportuna cada perfil.

4. Enfoque Analítico

Este apartado tiene por objetivo evaluar el impacto de la herramienta de monitoreo diario sobre los resultados de gestión de proyecto. Se usará la proporción **horas reales/horas estimadas** como indicador principal, formulando dos hipótesis, H0:

“No existe una diferencia en la proporción de horas estimadas frente a horas trabajadas en los proyectos que tienen un monitoreo diario y los que no”, es decir, el monitoreo no genera diferencias en esta proporción, y H1: “Sí hay una diferencia en la proporción de horas estimadas frente a horas trabajadas en los proyectos que tienen un monitoreo diario y los que no”, es decir que el monitoreo sí las genera. Estas hipótesis buscan medir si la herramienta afecta la eficiencia en uso de recursos, complementándose con indicadores como cumplimiento de cronograma, reprocesos y salud del backlog.

Para las técnicas estadísticas se propone en una primera instancia un experimento T-Test, para el cual se debe asegurar:

- **Independencia:** Se va a utilizar para proyectos no relacionados
- **Homogeneidad de varianzas:** Se deben evaluar las varianzas de los resultados obtenidos
- **Normalidad en los residuos:** Se medirá a partir de Q-Q Plot
- **Tamaño de la muestra**

Si los supuestos no se cumplen, se usarán alternativas como **Welch's test** o **Mann-Whitney U**, además de considerar **ANCOVA**, para controlar covariables (tamaño del equipo).

La validación seguirá tres fases: **(1) piloto controlado** con seis proyectos, monitoreando diariamente la mitad, **(2) evaluación cuantitativa** de significancia y tamaño del efecto, y **(3) evaluación cualitativa** con entrevistas de usuarios. Para el dashboard se plantean visualizaciones de **avance del proyecto, cumplimiento de horas y línea de tiempos de hitos.**

5. Recolección de Datos

Para el presente proyecto se utilizan dos (2) fuentes de datos principales.

La información de la empresa: El registro de horas en la empresa se realiza principalmente mediante correos diarios en formato Timecard, que influyen fecha empleado, tarea, horas trabajadas y estimadas, estado y proyecto. Aunque funcional, este método es rudimentario. Para centralizar la información se desarrolló una **ETL** que extrae estos datos del HTML de los correos y los consolida en una tabla maestra. Complementariamente, otras fuentes de información como archivos de Excel aportan información estructural sobre proyectos, actividades, tareas, subtareas, así como datos básicos de empleados y clientes, permitiendo complementar registros horarios.

Dataset de Grizzly: Por recomendación del equipo docente y debido al volumen limitado de datos de la empresa, se incorporó un dataset abierto con estructura similar para permitir análisis más complejos y experimentación académica. Este dataset no

será entregado a la empresa.

El dataset proviene de **Gryzzly**, una herramienta de seguimiento de tiempo integrada con Slack y Teams. Publicado en abril de 2025, recopila 4.4 millones de registros de 2017 as 2024 sobre proyectos de software en industrias como marketing, finanzas y tecnología.

El conjunto de datos reúne información sobre tareas, proyectos y equipos registrados en Gryzzly para el seguimiento del tiempo y desempeño. Incluye identificadores de tareas y proyectos, fechas de creación, duraciones planeadas y reales, fuente del registro, estado del equipo o empresa, y datos temporales de los equipos, entre otros. Para más información sobre el Dataset de Grizzly, se puede acceder al siguiente [enlace](#)





Diagrama de Recolección de Datos

El siguiente diagrama resume el flujo de origen y consumo de los datos utilizados en el proyecto. Del lado izquierdo, la información interna de la empresa es recolectada para crear un dashboard de Monitoreo. Inicialmente los datos históricos se recolectan con una ETL, encargada de extraer la información existente en los correos corporativos y los archivos de Excel.

A futuro los empleados usarán un API donde podrán hacer el registro de sus horas y crear entidades como tareas, o proyectos, eliminando la dependencia de los correos y ciertos archivos más tradicionales.



En el lado derecho de la gráfica, se presenta la fuente de datos externa, el dataset de Grizzly, el cual se emplea exclusivamente con fines académicos para la experimentación analítica y el desarrollo de un modelo de Machine Learning. Este dataset no se integrará al entregable empresarial ni se mezclará con los datos reales de IMG.

Compatibilidad de Grizzly con datos de IMG

La inclusión de un dataset abierto que apoyara el ejercicio académico en el proyecto era completamente necesario debido a la baja cantidad de datos presentes en la empresa. Tras una investigación de parte de los estudiantes se selecciona el dataset Grizzly dado que tiene una estructura muy similar a la de IMG en sus datos. También tiene un contexto similar pues se trata de una recolección de timecards en proyectos de software en industrias de Marketing, Finanzas y Bancos, además de haber sido publicado en abril de 2025 y contener información de los últimos años (2017-2024).

Es cierto que existen diferencias contextuales, por ejemplo, el país. Los datos del

Grizzly provienen de Francia, mientras que la empresa IMG en su contexto colombiano tendrá diferencias clave como la inexistencia de estaciones que afecten las horas trabajadas. A pesar de estas diferencias se define que Grizzly es la mejor opción para crear un modelo de analítica que luego pueda ser ajustado y modificado para las necesidades de IMG, una vez exista un volumen de datos suficiente.

6. Entendimiento de los Datos

El proyecto se basa en 2 fuentes de datos:

- **Fuente de datos de la empresa:** Los datos internos de la organización, junto con la información recolectada a través de la API de registro, constituyen el insumo principal para la construcción del dashboard de seguimiento, permitiendo analizar el avance, desempeño y cumplimiento de los proyectos.
- **Fuente de datos Grizzly:** Debido a las limitaciones en el volumen de datos empresariales, para el desarrollo del modelo se complementa la información con el *dataset* de seguimiento de tareas proveniente de Grizzly. El entendimiento, la exploración y el análisis descriptivo de esta fuente se llevan a cabo en el notebook “**proyecto_final.ipynb**”, donde también se preparan los datos para su uso en el modelo analítico.

7. Preparación de datos

Como insumo se utilizó la base transformada de la primera entrega (datos recolectados de la plataforma Grizzly). Las métricas del modelo mejoraron significativamente gracias a un conjunto de transformaciones de limpieza y enriquecimiento de los datos, que permitieron reducir el ruido, elevar la calidad de las variables y mitigar el impacto de valores extremos que afectaban el aprendizaje. En particular:

- a) Creación de variables agregadas como `cantidad_tareas` y `num_seguimientos`, orientadas a capturar la intensidad operativa de cada proyecto mediante conteos consolidados.
- b) Tratamiento de la asimetría en variables numéricas, donde se identificó una asimetría positiva elevada. Se aplicó winsorización basada en criterios del negocio, reduciendo la influencia de outliers sin eliminar información relevante. Esta corrección contribuyó a disminuir el RMSE.
- c) Depuración de valores atípicos en la variable objetivo (`duracion_real_total_proyecto`), seleccionando rangos representativos de los proyectos con mayor frecuencia para mejorar la estabilidad del modelo.
- d) Imputación de valores faltantes en la variable `duracion_meses_team`, reemplazando nulos por el promedio para preservar coherencia en el comportamiento histórico.
- e) Codificación de variables categóricas mediante OneHotEncoder, adecuado dado que estas columnas no presentaban alta cardinalidad.
- f) Estandarización de variables numéricas utilizando StandardScaler, para homogenizar escalas y favorecer el desempeño de modelos sensibles a magnitud.

8. Estrategia de validación y selección de modelo

Se implementó una estrategia de validación robusta combinando una división inicial de los datos en entrenamiento y prueba (80%-20%, con `random_state=42`) junto con un proceso de búsqueda de hiperparámetros mediante GridSearchCV. Aunque se mantiene un conjunto de prueba independiente para la evaluación final, GridSearchCV aplica validación cruzada interna, dividiendo automáticamente el conjunto de entrenamiento en n folds. En cada iteración, el modelo entrena en una fracción de los datos y valida en la restante, rotando los folds. Este procedimiento reduce el riesgo de sesgo por particiones aleatorias y permite seleccionar el modelo e

hiperparámetros óptimos de forma más confiable. Así, la evaluación final se realiza únicamente sobre el conjunto de prueba, garantizando imparcialidad en la medición del desempeño.

9. Construcción y evaluación del modelo

El objetivo del modelo es predecir la duración real (en horas) de los proyectos. Para ello se entrenaron y evaluaron tres algoritmos distintos: LinearRegression, RandomForestRegressor y XGBRegressor, cada uno explorado mediante diferentes configuraciones de hiperparámetros con el fin de identificar la mejor versión de cada modelo.

Se implementó un proceso sistemático de experimentación donde se definieron grillas de hiperparámetros para Random Forest y XGBoost, utilizando validación cruzada para seleccionar los modelos con mejor desempeño según las métricas definidas en el enfoque analítico (MAE, RMSE y R^2). En contraste, LinearRegression se evaluó como un modelo base para establecer un punto de referencia.

Los resultados muestran que RandomForestRegressor y XGBRegressor presentan desempeños muy similares en términos de R^2 , ambos significativamente superiores al modelo lineal. El modelo de regresión lineal obtiene valores de R^2 aproximadamente 10 puntos porcentuales por debajo, lo cual evidencia que las relaciones entre las variables y la variable objetivo no son puramente lineales. En cambio, los modelos basados en árboles capturan de manera más efectiva patrones no lineales y efectos de interacción presentes en los datos.

En términos de oportunidades de mejora, se identifican posibles líneas de trabajo futuras como: incorporar nuevas variables derivadas que capturen relaciones no lineales, evaluar modelos polinómicos o modelos de ensamble más complejos, y profundizar en el manejo de valores atípicos para reducir aún más el error de predicción.

Modelo	MAE	RMSE	R2
LinearRegression	3.85	4.98	0.47
RandomForestRegressor	3.35	4	0.57
XGBRegressor	3.29	4	0.57

Tabla 1. Rendimiento modelos basados en árboles y regresión.

Por otro lado, la métrica principal seleccionada para la evaluación fue el MAE, dado que proporciona una interpretación directa del error promedio en horas entre la duración predicha y la duración real del proyecto. Los resultados muestran que, para los tres modelos evaluados, el MAE se encuentra en un rango entre 3.2 y 3.8 horas, lo cual indica un nivel de error relativamente estable y comparable entre los modelos, con ligeras ventajas para los modelos basados en árboles sobre la regresión lineal.

En un contexto empresarial, un R^2 del 57% no es perfecto, pero sí útil y accionable, especialmente si la organización no es todavía data-driven y apenas comienza a integrar modelos predictivos. Permite generar estimaciones más informadas que la intuición o que reglas manuales, y sirve como base para seguir mejorando el proceso de modelado y recolección de datos.

10. Construcción del Producto de Datos

A continuación, se describen los productos de Datos entregables en el presente proyecto a partir de la ideación inicial, para cada uno se da una descripción inicial, su método de despliegue y los archivos entregables relacionados en el repositorio.

10.1 ETL

La ETL se utiliza para recolectar y consolidar datos históricos de correos de registro de horas y archivos de Excel. Mediante un script en Python, lee y limpia los correos en el formato deseado, extrae los campos relevantes y lo transforma en un CSV estructurado.

Despliegue

La ETL se ejecuta una única vez para cargar el histórico inicial al repositorio de datos,

ya que la recolección futura será asumida por la API. Será entregado a la empresa como apoyo para el inicio de la implementación de la API

Archivo entregable

Se entrega el script en Python, el archivo CSV resultante del procesamiento y la documentación sobre la estructura esperada del input y del output del ETL. Ubicado en el repositorio bajo ETL_V0.1.ipynb

10.2 API REST

La API será el mecanismo principal de recolección de datos, permitiendo registrar horas, crear tareas y proyectos, actualizar estados y consultar información de manera centralizada. Inicialmente se alimenta con el histórico extraído por la ETL y, con uso futuro, garantiza la trazabilidad, estandarización y validación de los datos.

Despliegue

El despliegue del API se realizará mediante la intranet de la empresa IMG Procesos y Tecnología. Solo es necesario permitir acceso a usuarios autorizados que se encuentren dentro de la red interna de la empresa.

Archivo Entregable

Se entrega todo el código fuente de la API junto a la base de datos. Esto incluye todas las pantallas (.html), junto con su lógica(.js) y su apariencia(.css). Para ejecutar la API se debe correr el script llamado app.py. Todos los documentos de la API se encuentran bajo el archivo API_IMG.zip

10.3 Dashboard

El dashboard permite monitorear la operación de la empresa mediante KPIs como avance de proyectos, cumplimiento de horas y productividad, además de detectar posibles inconvenientes en el desarrollo de los proyectos. Se conecta directamente al repositorio administrado por la API, garantizando datos centralizados y actualizados.

Despliegue

El despliegue se realizará mediante una licencia de Power BI. Se implementará controles de accesos para asegurar que la información sea accedida solo por las personas del equipo administrativo.

Archivo Entregable:

Se entrega el archivo .pbix que contiene las visualizaciones con el código DAX usado para calcular diferentes métricas. Además, se adjunta la información de la base de datos como archivos .csv (para facilitar la instalación en la presente entrega). Todos los documentos del Dashboard se encuentran bajo el archivo: dashboard_IMG.zip

10.4 Modelo.

El modelo seleccionado para estimar la duración de los proyectos fue un algoritmo basado en árboles de decisión, elegido por su buen desempeño en tareas de predicción con datos heterogéneos. Este modelo utiliza como insumos variables como la duración planeada del proyecto, la cantidad de tareas asociadas, el número de seguimientos registrados y otras características relevantes que permiten capturar la complejidad y variabilidad de cada proyecto

Despliegue

Se implementó el despliegue del modelo predictivo de Machine Learning (el mejor modelo obtenido) por medio de la herramienta Streamlit. Esta fase se considera una Prueba de Concepto Funcional (PoC) con el siguiente alcance:

Propósito principal: validación rápida del funcionamiento, la experiencia de usuario (UX) y la lógica de preprocesamiento en un entorno de aplicación real.

Archivo entregable

El entregable final consta de un conjunto de archivos (artefactos) que encapsulan el modelo entrenado y los transformadores de datos, junto con el script de la aplicación:

rf.joblib: Modelo principal (encapsulado).

standard_scaler.joblib: Usado en preprocess_and_predict para escalar las variables numéricas de entrada.


one_hot_encoder.joblib: Usado en preprocess_and_predict para transformar las variables categóricas (como estado, oferta, fuente) en columnas binarias.

final_columns.joblib: Usado para asegurar que el DataFrame de entrada al modelo (final_input_df) tenga exactamente las mismas columnas y el mismo orden que se usó durante el entrenamiento.


app_2.py: Ejecutado con streamlit run app_2.py para lanzar el prototipo funcional.

10.5 Diagrama de la Arquitectura

A continuación, se presentan dos diagramas:




La arquitectura actual del presente proyecto, con los cuatro productos de datos que usan la fuente externa del dataset Grizzly y los datos internos de la empresa. El prototipo del Modelo de Analítica es un adicional para el ejercicio académico, pero no es integrado aun a la arquitectura empresarial



La arquitectura propuesta a futuro para la empresa, manteniendo los cuatro productos de datos, pero usando como principal fuente de información lo consignado por los usuarios mediante el API. La Base de Datos alimenta de datos al dashboard y al Modelo de Analítica, que ya está integrado en la solución empresarial y puede generar información adicional para los usuarios.


11. Retroalimentación por parte de la organización.

Se realizaron varias reuniones con la IMG. La primera tuvo lugar el **26 de agosto de 2025** y tuvo como objetivo identificar las principales problemáticas que el producto buscaba resolver. Como resultado de esta sesión, se elaboró un mapa de empatía del cliente que permitió comprender sus necesidades y desafíos más relevantes.



Una vez identificados los principales puntos de dolor de la organización, se diseñó el

producto de datos en conjunto con el gerente administrativo de la compañía, definiendo el alcance esperado de dicho producto. Esta segunda reunión se realizó el 12 de septiembre de 2025. A partir de entonces, se sostuvieron múltiples encuentros de seguimiento para asegurar el avance del producto de datos y el cumplimiento de los objetivos establecidos.



Finalmente, el **28 de noviembre de 2025** se realizó una entrega parcial de los productos de datos desarrollados en el proyecto. Durante esta entrega, se evidenció satisfacción por parte del cliente respecto al cumplimiento de los objetivos planteados. La organización manifestó conformidad tanto con el entorno de captura de información como con el entorno de visualización. No obstante, en etapa de pruebas funcionales, se identificaron algunos detalles menores relacionados con errores no controlados en el registro de datos, los cuales se espera corregir antes de la implementación definitiva de la herramienta en enero de 2026.

12. Conclusiones

12.1 - ¿Se cumplieron los objetivos del proyecto?

Si, los objetivos propuestos inicialmente en el proyecto se cumplieron de manera satisfactoria. Se desarrollaron todos los productos de datos propuestos: la ETL inicial para consolidar la información histórica de la empresa, un API transaccional para la captura estructurada de la información, un dashboard que apoya el monitoreo y la gestión de proyecto, y un prototipo de modelo analítico. Todos estos productos permiten a IMG Procesos y Tecnología mejorar la trazabilidad, y el seguimiento de los proyectos, centralizar los datos, y facilitar la toma de decisiones basadas en datos

12.2 - ¿Cuáles fueron las mayores dificultades que se obtuvieron durante su desarrollo

El principal obstáculo está relacionado con la cantidad de datos encontrados en la empresa, después de haber comenzado el desarrollo del proyecto se encontró que el volumen de datos en IMG era insuficiente para la construcción de un Modelo de Analítica. Esta dificultad obligo a reformular el alcance técnico del proyecto, a incorporar un dataset externo y a tener esfuerzos adicionales con el entendimiento y procesamiento de los datos. A pesar de esto, el proyecto logro avanzar de manera apropiada, la inclusión de Grizzly permitió mantener el componente académico del curso y realizar procesos de analítica de datos, mientras que los demás entregables aportan valor a la estrategia de datos de la empresa.

12.3 - ¿Qué estimación se puede dar respecto a cómo se impactarían las métricas de negocio (KPIs) una vez el producto de datos sea utilizado por usuarios reales?

Tras la adopción de los productos de datos desarrollados, se espera que los KPIs del negocio vean un impacto en la optimización de costos operacionales, disminución de horas de desarrollo no estimadas, redistribución de personal en los equipos de trabajo, y trazabilidad de costos operacionales en los proyectos. De igual manera, se

plantean impactos positivos en la centralización de la información y el registro de costos y presupuestos asociados a cada cliente. De manera estratégica, se prevén más casos de usos futuros producto de la centralización de la información que se desarrolla en estos productos de datos.

12.4 - ¿Qué condiciones considera que deberían tener los datos para obtener mejores resultados? Más datos, nuevas características, menor sesgo, etc.

La principal mejora para IMG sería un mayor volumen de datos disponibles de forma estructurada y centralizada, se espera que mediante la nueva API sea más sencillo para las personas de la empresa hacer sus registros diarios y de esta manera aumentar el histórico de datos, y así, ver tendencias y poder realizar analítica sobre los datos. Sería beneficioso también enriquecer las entidades actuales (Proyectos, Actividades, Tareas, Empleados) con atributos adicionales que aporten contexto, por ejemplo, categorías de trabajo, nivel de complejidad, nivel de prioridad, tipo de clientes, mantenimiento o nuevo desarrollo. Esta información adicional ampliaría las posibilidades analíticas de los modelos y permitiría crear nuevas métricas en el dashboard. En cuanto al dataset Grizzly, aunque su anonimización es comprensible, la ausencia de variables descriptivas (como categorías o nombres más interpretables) limitó parcialmente la comprensión del contexto. No obstante, su estructura permitió desarrollar escenarios analíticos útiles para el alcance académico del proyecto.

12.5 - ¿El mejor modelo obtenido es suficiente para dar solución al problema u oportunidad de negocio abordado?

Si bien el modelo no sustituye las necesidades de centralización y análisis operativo que ya cubren la aplicación web y el dashboard corporativo, sí aporta un valor adicional significativo frente a la problemática del negocio. La falta de control entre costos planificados y reales, la ausencia de datos consolidados para evaluar productividad y la imposibilidad de anticipar desviaciones afectan directamente la gestión de proyectos. En este contexto, el modelo desarrollado, que es capaz de predecir las horas reales de un proyecto a partir de información como horas planeadas, número de tareas y frecuencia de seguimiento, no resuelve por completo todas las brechas operativas, pero sí constituye un activo de datos útil y complementario. Su capacidad predictiva permite a los project managers estimar con mayor precisión el esfuerzo real requerido, anticipar desviaciones de costo y planificar proyectos con una base más informada, contribuyendo de forma tangible a la toma de decisiones y a la eficiencia organizacional.